

# Guia Rápido - Inferência Estatística I

---

License MIT

The MIT License © 2023, Arthur Silva

arthursilva@alu.ufc.br

[4r7hu3.github.io](https://4r7hu3.github.io)

---

- [O que é Inferência?](#)
  - [Preliminares](#)
  - [Para fixar](#)
    - [Fórmulas](#)
    - [Algumas demonstrações](#)
  - [Eficiência entre estimadores](#)
  - [Família exponencial](#)
    - [Exercícios Resolvidos 1](#)
  - [Mais definições](#)
    - [Exercícios Resolvidos 2](#)
  - [Métodos de estimação](#)
    - [Método dos momentos](#)
    - [Método da máxima verossimilhança](#)
    - [Método dos mínimos quadrados](#)
    - [Exercícios Resolvidos 3](#)
  - [Estimação intervalar](#)
    - [Intervalos Bilaterais](#)
    - [Intervalos Unilaterais](#)
  - [Testes de Hipótese](#)
    - [Métodos](#)
    - [Procedimentos em uma amostra](#)
    - [Procedimentos em duas amostras](#)
    - [Teste mais poderoso](#)
- 

## O que é Inferência?

A Inferência Estatística busca fazer estimativas, que podem ser intervalares e pontuais, de **parâmetros populacionais** e/ou da distribuição ou forma/lei de um conjunto de dados a partir de uma **amostra**. Um exemplo de uso prático muito importante são as eleições, que buscam inferir — através da coleta de informações de uma amostra de tamanho  $n$  — a quantidade  $X$  de votos que irão receber candidatos a cargos políticos. Além dessa aplicação, a Inferência trabalha com testes de hipótese (intrinsecamente ligados à estimação), os quais são empregados em praticamente toda a área do conhecimento humano, não limitando-se às áreas de ciências exatas.

## Preliminares

Alguns conceitos importantes para a Inferência:

1. *População* - O conjunto universo. O todo;
2. *Amostra* - Qualquer subconjunto da população. Parte da população;
3. *Parâmetro* - Dados que referem-se à **população**;
4. *Estatística* - Dados que referem-se à **amostra**;
5. *Amostra Aleatória Simples* - Conjunto de  $n$  variáveis aleatórias independentes e identicamente distribuídas (**I.I.D**);
6. *Espaço Paramétrico* - É o conjunto  $\Theta$  em cujos os parâmetros variam;
7. *Suporte* - É o conjunto  $A$  em cuja a v.a varia;
8. *Estimador* - Função dos valores amostrais para estimar um parâmetro desconhecido<sup>[1]</sup>;
9. *Estimativa* - Valor estimado propriamente dito;
10. *Viés* - Mede a distância absoluta (erro) da média do estimador em relação ao parâmetro estimado<sup>[2]</sup>;
  - 10.1 Estimador **não-viesado**:  $E[\hat{\theta}] = \theta, \forall \theta \in \Theta$
  - 10.2 Estimador **viesado**:  $E[\hat{\theta}] \neq \theta, \forall \theta \in \Theta$
  - 10.3 Estimador **assintoticamente não viesado**:  $\lim_{n \rightarrow \infty} E[\hat{\theta}] = \theta$
  - 10.4 Estimador **consistente**:  $\lim_{n \rightarrow \infty} E[\hat{\theta}] = \theta$  e  $\lim_{n \rightarrow \infty} Var[\hat{\theta}] = 0$
11. *Erro Quadrático Médio* - O EQM calcula a expectativa do quadrado do erro do estimador em relação ao parâmetro a ser estimado;
12. *Erro Padrão* - É a raíz quadrada da varância de um estimador;

Definição formal de *Estatística*: função da amostra que **não** depende de parâmetros desconhecidos.

Exemplos:

Seja  $X_1, X_2, \dots, X_n$  uma amostra aleatória de tamanho  $n$  de uma v.a  $X$ .

- $\max(x_1, x_2, \dots, x_n)$  é uma estatística;
- $\min(x_1, x_2, \dots, x_n)$  é uma estatística;
- $\bar{X}$  é uma estatística;
- $S^2$  é uma estatística.

Note que nenhuma das funções acima depende de parâmetros desconhecidos!

## Para fixar

Agora, vamos anotar algumas formas e provas muito importantes para a Inferência:

## Fórmulas

- $\bar{X} = \frac{\sum_{i=1}^n X_i}{n} \sim N\left(\mu; \frac{\sigma^2}{n}\right)$
- $Z = \frac{X - \mu}{\sigma} \sim N(0;1)$  e  $Z^2 \sim \chi_{(1)}^2$
- $S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}$
- $\hat{\sigma}^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}$
- $\frac{(n - 1)S^2}{\sigma^2} \sim \chi_{(n-1)}^2$
- $\frac{(n - 1)S^2}{n} \sim \chi_{(n)}^2$
- $2\theta S \sim \chi_{(2n)}^2$ , com  $S \sim Gama(n; \theta)$
- $t = \frac{Z}{\sqrt{\frac{V}{v}}} \sim t_v$ , com  $V \sim \chi_v^2$
- $Y = -\ln(U) \sim Exp(1)$ , onde  $U \sim U(0, 1)$
- $X = \frac{\frac{U}{n-1}}{\frac{V}{m-1}} \sim F(n - 1; m - 1)$ , com  $\frac{U}{n - 1} = \frac{S_1^2}{\sigma_1^2}$  e  $\frac{V}{m - 1} = \frac{S_2^2}{\sigma_2^2}$
- $G = \frac{1}{X} \sim F(m - 1; n - 1)$

- $\sum_{i=1}^n X_i \sim \text{Gama}(n, \theta)$ , com  $X \sim \text{Exp}(\theta)$
- $\sum_{i=1}^n X_i \sim \text{Bin}(n; p)$ , com  $X \sim \text{Ber}(p)$
- $B(\hat{\theta}) = E[\hat{\theta}] - \theta$ , é o **viés** do estimador  $\hat{\theta}$
- $EQM(\theta) = E[(\hat{\theta} - \theta)^2] = \text{Var}[\hat{\theta}] + B^2(\hat{\theta})$  é o **erro quadrático médio** do estimador  $\hat{\theta}$ <sup>[3]</sup>
- $f(x_1, x_2, \dots, x_n | \theta) = \prod_{i=1}^n f(x_i | \theta)$  é a **distribuição conjunta da amostra**
- $L(\theta) = \prod_{i=1}^n f(x_i | \theta) I_{\theta}(\theta)$  é a **função de verossimilhança**<sup>[4]</sup>
- $\int_0^{\infty} u^{a-1} e^{-bu^c} dv = \frac{\Gamma(\frac{a}{c})}{cb^{\frac{a}{c}}}$  é a **função gama generalizada**  
para lembrar:
  1.  $\Gamma(\alpha + 1) = \alpha \Gamma(\alpha)$
  2.  $\Gamma(n) = (n - 1)!, \forall n \in \mathbb{Z}^+$
  3.  $\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$

## Algumas demonstrações

- $\bar{X}$  é um estimador viesado ou não viesado para  $\mu$ ? Considere uma v.a  $X \sim N(\mu; \sigma^2)$ .

**Solução:**  $E[\bar{X}] - \mu = \frac{1}{n} E[\sum_{i=1}^n X_i] - \mu = \frac{1}{n} \times n \times E[X] - \mu = 0$ . Portanto,  $\bar{X}$  é **não viesado**!

OBS: Note que  $X_i$  são  $n$  v.a's I.I.D

- $S^2$  é um estimador viesado ou não viesado para  $\sigma^2$ ? Considere uma v.a  $X \sim N(\mu; \sigma^2)$ .

**Solução:**  $\frac{1}{n-1} E[\sum_{i=1}^n (X_i - \bar{X})^2]$ .

Temos que  $\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2) = \sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2$ .

Agora temos que  $E[\sum_{i=1}^n (X_i - \bar{X})^2] = E[\sum_{i=1}^n X_i^2 - n\bar{X}^2]$

Note que  $E[X^2] = Var[X] + E^2[X] = \sigma^2 + \mu^2$ , e que  $E[\bar{X}^2] = Var[\bar{X}] + E^2[\bar{X}] = \frac{\sigma^2}{n} + \mu^2$

$$\text{Finalmente: } \frac{1}{n-1} E[\sum_{i=1}^n X_i^2 - n\bar{X}^2] = \frac{1}{n-1} [(n\sigma^2 + n\mu^2) - (\sigma^2 + n\mu^2)] = \frac{1}{n-1} \sigma^2 (n-1) = \sigma^2$$

Portanto,  $S^2$  é **não viesado**!

- $\hat{\sigma}^2$  é um estimador não viesado para  $\sigma^2$ ? Considere uma v.a.  $X \sim N(\mu; \sigma^2)$ .

**Solução:** Já sabemos que  $E[\sum_{i=1}^n X_i^2 - n\bar{X}^2] = \sigma^2(n-1)$ .

$$\text{Portanto, } \frac{1}{n} E[\sum_{i=1}^n (X_i^2 - n\bar{X}^2)] = \frac{\sigma^2(n-1)}{n} \neq \sigma^2.$$

OBS: Note que  $B(\hat{\sigma}^2) = -\frac{\sigma^2}{n}$ , ou seja, **subestima** o parâmetro!

- Prove que  $E[(\hat{\theta} - \theta)^2] = Var[\hat{\theta}] + B^2(\hat{\theta})$ .

**Solução:** Primeiro, vamos considerar  $\hat{\theta} - \theta = \hat{\theta} - E[\hat{\theta}] + E[\hat{\theta}] - \theta$ .

$$\text{Então, } (\hat{\theta} - \theta)^2 = (\hat{\theta} - E[\hat{\theta}])^2 + 2(\hat{\theta} - E[\hat{\theta}])(E[\hat{\theta}] - \theta) + (E[\hat{\theta}] - \theta)^2.$$

$$\text{Logo, } E[(\hat{\theta} - \theta)^2] = E[(\hat{\theta} - E[\hat{\theta}])^2] + E[(E[\hat{\theta}] - \theta)^2] = Var[\hat{\theta}] + B^2(\hat{\theta}).$$

$$\text{OBS: Note que } E[2(\hat{\theta} - E[\hat{\theta}])(E[\hat{\theta}] - \theta)] = 2(E[\hat{\theta}] - E[\hat{\theta}])(E[\hat{\theta}] - E[\theta]) = 0.$$

- Encontre a distribuição de  $S^2$ . Considere  $W \sim Gama(\alpha; \lambda)$  e utilize sua *f.g.m.* para achar o resultado.

**Solução:** Sabemos que  $S^2 = \frac{\sigma^2 V}{n-1}$ , onde  $V \sim \chi_{(n-1)}^2$ . Usando a função geradora de momentos ficamos com o seguinte:

$$M_{S^2}(t) = E[e^{tS^2}] = E[e^{t\frac{\sigma^2 V}{n-1}}] = M_V(\frac{t\sigma^2}{n-1}) = \left[1 - \frac{2t\sigma^2}{n-1}\right]^{-(n-1)/2}.$$

Sabemos que a f.g.m de W pode ser posta na seguinte forma:  $\left[\frac{1}{1-\frac{t}{\lambda}}\right]^\alpha = \left[1 - \frac{t}{\lambda}\right]^{-\alpha}$ .

Analisando atentamente, temos que  $\alpha = (n - 1)/2$  e  $\lambda = \frac{n-1}{2\sigma^2}$ .

Logo,  $S^2 \sim Gama\left(\frac{n-1}{2}; \frac{n-1}{2\sigma^2}\right)$ . Vamos testar?

$$E[S^2] = \frac{\alpha}{\lambda} = \frac{\frac{n-1}{2}}{\frac{n-1}{2\sigma^2}} = \sigma^2.$$

$$Var[S^2] = \frac{\alpha}{\lambda^2} = \frac{\frac{n-1}{2}}{\frac{(n-1)^2}{4\sigma^4}} = \frac{2\sigma^4}{n-1}.$$

## Eficiência entre estimadores

Sejam  $T_1$  e  $T_2$  dois estimadores de  $\theta$ . Se  $\forall \theta \in \Theta$  a seguinte desigualdade ocorrer, para pelo menos um valor de  $\theta$ , então o **melhor estimador** será aquele de **menor EQM**.

$$EQM(T_1) \leq EQM(T_2)$$

Se  $T_1$  e  $T_2$  forem não viesados, o melhor será aquele de **menor variância**.

## Família exponencial

A *Família exponencial* constitui um importante grupo de funções (f.d.p e f.m.p) com características bem definidas pelos seguintes critérios:

1. O suporte  $A$  da distribuição **não** depende do parâmetro desconhecido, digamos,  $\theta$ ;
2.  $\log(f(x|\theta)) = c(\theta)T(x) + d(\theta) + h(x)$ .

É importante destacar que nem sempre as componentes vão estar explícitas na forma acima, por exemplo, há funções onde  $h(x) = 0$ , sendo assim omitida da equação.

Fatos importantes decorrentes da família exponencial:

1.  $E[T(x)] = -\frac{d'(\theta)}{c'(\theta)}$ ;
2. Seja  $S = \sum_{i=1}^n T(X_i)$ .  $S$  é uma **estatística suficiente e completa** para  $\theta$ ;
3.  $E[S] = nE[T(x)]$  e  $Var[S] = nVar[T(x)]$ ;
4.  $M_S(t) = [M_X(t)]^n$ , que usamos para encontrar a **distribuição amostral** de  $S$ .

Para encontrar o UMVUE de  $g(\theta)$ , sabendo que a distribuição pertence à família exponencial, encontra-se uma função de  $S$ ,  $h(S)$ , de tal forma que  $E[h(S)] = g(\theta)$ .

## Exercícios Resolvidos 1

1. Seja  $X \sim Ber(p)$ . Mostre que  $X$  pertence à família exponencial.

$$1.1. f(x|p) = p^x(1-p)^{1-x}I_{\{0,1\}}(x), \theta = [0, 1]$$

$$1.2. \log f(x|p) = x \log p + \log(1-p) - x \log(1-p) = x[\log p - \log(1-p)] + \log(1-p)$$

$$1.3. T(x) = x; c(p) = \log p - \log(1-p); d(p) = \log(1-p); h(x) = 0$$

Vemos que o suporte da distribuição **independe** de  $p$ . Logo, está provado que  $X$  pertence à família exponencial.

Além disso,  $S = \sum_{i=1}^n x_i$  é uma estatística suficiente e completa para  $p$ . Sua distribuição é:  
 $M_S(t) = [M_X(t)]^n = [pe^t + (1-p)]^n \sim Bin(n, p)$

Vamos encontrar o **UMVUE**:  $E[S] = np \quad \therefore \quad E\left[\frac{S}{n}\right] = p \quad \therefore \quad \bar{X}$  é o nosso estimador procurado.

2. Seja  $X \sim Gama(3; \theta)$ . Essa v.a pertence à família exponencial? Verifique.

$$2.1. f(x|\theta) = \frac{\theta^3}{2} x^2 e^{-\theta x} I_{(0,\infty)}(X), \Theta = (0, \infty)$$

$$2.2. \log f(x|\theta) = 3 \log \theta - \log 2 + 2 \log x - \theta x$$

$$2.2. T(x) = x; c(\theta) = -\theta; d(\theta) = 3 \log \theta; h(x) = 2 \log x - \log 2$$

Podemos ver que o suporte da nossa v.a **independe** do parâmetro. Portanto, provamos que  $X$  pertence à família exponencial.

Além disso,  $S = \sum_{i=1}^n x_i$  é uma estatística suficiente e completa, com distribuição:  $M_S(t) = \left[\frac{\theta}{\theta - t}\right]^{3n}, Gama(3n; \theta)$

## Mais definições

Considere  $X$  uma v.a com f.m.p ou f.d.p  $f(x|\theta)$ , com suporte  $A$  independente de  $\theta$ .

- $V = \frac{\partial \log f(X|\theta)}{\partial \theta}$  é a **função escore**.  
OBS:  $E[V] = 0$ .

- $I_F(\theta) = \text{Var}[V] = E[V^2] = E^2 \left[ \frac{\partial \log f(X|\theta)}{\partial \theta} \right] = -E \left[ \frac{\partial^2 \log f(X|\theta)}{\partial \theta^2} \right]$  é a **informação de Fisher**.<sup>[5]</sup>  
Note que como  $E[V] = 0$ , logo,  $\text{Var}[V] = E[V^2]$ .
- $LICR(\theta) = \frac{1}{nI_F(\theta)}$  é o **Limite Inferior de Crámer-Rao**, denotado também por  $LI$ .
- Se  $T$  é um estimador de  $g(\theta)$ , então  $\text{Var}[T] \geq \frac{[g'(\theta)]^2}{nI_F(\theta)}$ , que é chamada de **desigualdade da informação** (caso geral).
- $e(T) = \frac{LICR(\theta)}{\text{Var}[T]}$  é a eficiência do estimador.  
Se  $e(T) = 1$ , então o estimador é dito ser **eficiente**!
- Dizemos que  $T$  é uma **estatística suficiente** para  $\theta$  se, e somente se, a distribuição conjunta da amostra puder ser fatorada dessa forma:  
$$\prod_{i=1}^n f(x_i|\theta) = h(x_1, x_2, \dots, x_n) g_\theta(T(x_1, x_2, \dots, x_n))$$
<sup>[6]</sup>
- **Teorema de Rao-Blackwell**: Seja  $S$  uma estatística suficiente de  $\theta$  e  $T$  um estimador não-viesado de  $g(\theta)$ . Então  $T^* = E[T|S]$  geralmente é o melhor estimador para  $\theta$ .
- **Teorema de Lehmann-Scheffé**:  $T^*$  é o **UMVUE** (uniformly minimum variance unbiased estimator)<sup>[7]</sup>.

## Exercícios Resolvidos 2

1. Seja  $X \sim \text{Exp}(\theta)$ . Encontre a função escore e a informação de Fisher.

1.1.  $f(x|\theta) = \theta e^{-\theta x} I_A(x), A = (0, \infty), \Theta = (0, \infty)$

1.2  $\log f(x|\theta) = \log \theta - \theta x$

1.3  $V = \frac{1}{\theta} - X$ . Observe que  $E[V] = 0$



$$1.4 \ I_F(\theta) = \text{Var}[V] = \text{Var}\left[\frac{1}{\theta} - X\right] = \text{Var}[X] = \frac{1}{\theta^2}$$

2. Seja  $X$  uma v.a de seguinte distribuição:  $f(x|\theta) = e^{-(x-\theta)} I_{(\theta, \infty)}(x)$ ,  $\theta > 0$ . Encontre uma estatística suficiente para o parâmetro.

Vemos que o suporte é dependente do parâmetro desconhecido, logo, não podemos usar a família exponencial. Usaremos o critério da fatoração, encontrando  $h(\mathbf{x}) = e^{-s}$  e  $g(\theta, y_1) = e^{n\theta} I_{(\theta, \infty)}(y_1)$ .  $y_1$  é nossa estatística suficiente:

$$\begin{aligned} L(\theta) &= \prod_{i=1}^n e^{-(x_i-\theta)} I_{(\theta, \infty)}(x_i) = e^{-s} e^{n\theta} \prod_{i=1}^n I_{(\theta, \infty)}(x_i) \\ I_{(\theta, \infty)}(x_i) &= 1 \Leftrightarrow x_1 > \theta; x_2 > \theta; \dots; x_n > \theta \\ &\quad \vdots \\ y_1 &= \min(x_1, x_2, \dots, x_n) > \theta \\ &\quad \vdots \\ &\quad I_{(\theta, \infty)}(y_1) \\ &\quad \vdots \\ &\quad e^{-s} e^{n\theta} I_{(\theta, \infty)}(y_1) \end{aligned}$$

3. Seja  $T = 2\bar{X}$  um estimador não viesado para  $\theta$ , parâmetro de  $X \sim U[0; \theta]$ . Seja o novo estimador  $T_1 = E[2X|Y_n]$ , onde  $Y_n$  é uma estatística suficiente e completa para o parâmetro. Qual nome recebe esse novo estimador?

$E[2X|Y_n]$  é um estimador não viesado que é função de uma estatística suficiente. Logo, pelo teorema de *Lehmann-Sheffé* ou pelo teorema de *Rao-Blackwell*,  $T_1$  é o nosso **UMVUE**.

4. Seja  $X_1, \dots, X_n$  uma A.A.S. de  $X \sim \text{Bin}(2, \theta)$ .

- Encontre o LICR.
- Encontre uma estatística suficiente para  $\theta$ .
- Obtenha o **UMVUE** para  $\theta$ .
- Descubra se o estimador é eficiente ou não.

$$4.1. f(X|\theta) = \binom{2}{X} \theta^X (1-\theta)^{2-X} I_{\{0,1,2\}}(X)$$

$$4.2. \log f(X|\theta) = \log \binom{2}{X} + X \log \theta + (2-X) \log (1-\theta)$$

$$4.3. V = \frac{X}{\theta} - \frac{(2-X)}{(1-\theta)} = \frac{X(1-\theta) - \theta(2-X)}{\theta(1-\theta)} = \frac{X-2\theta}{\theta(1-\theta)}$$

$$4.4. I_F(\theta) = \text{Var}[V] = \frac{2\theta(1-\theta)}{\theta^2(1-\theta)^2} = \frac{2}{\theta(1-\theta)}$$

$$4.5. LICR = \frac{1}{n \frac{2}{\theta(1-\theta)}} = \frac{\theta(1-\theta)}{2n}$$

Vamos encontrar a estatística suficiente pelo critério da fatoração (poderia usar família exponencial):

$$L(\theta) = \prod_{i=1}^n \binom{2}{X_i} \theta^{X_i} (1-\theta)^{2-X_i} = \theta^s (1-\theta)^{2n-s} \prod_{i=1}^n \binom{2}{X_i}, \text{ com } s = \sum_{i=1}^n X_i. L(\theta) = \left[ \frac{\theta}{(1-\theta)} \right]^s (1-\theta)^{2n} \prod_{i=1}^n \binom{2}{X_i} = g(\theta, s) h(\mathbf{x}).$$

Assim, nossa estatística suficiente é  $s = \sum_{i=1}^n X_i$ .

4.6. Sabemos que  $s \sim \text{Bin}(2n; \theta)$ , com  $E[s] = 2n\theta$ . Então,  $E\left[\frac{s}{2n}\right] = \theta = E\left[\frac{\bar{X}}{2}\right]$  é nosso **UMVUE** procurado.

$$4.7. \text{Var}\left[\frac{\bar{X}}{2}\right] = \frac{1}{4} \frac{2\theta(1-\theta)}{n} = \frac{\theta(1-\theta)}{2n} = LICR. \text{ Nosso estimador é eficiente!}$$

## Métodos de estimação

### Método dos momentos

É o método mais simples e mais antigo já utilizado, e que consiste em igualar o primeiro momento populacional ao primeiro momento amostral. Em outras palavras, basta igualar  $\bar{X}$  a  $\mu$ :  $E[X] = \bar{X}$

### Método da máxima verossimilhança

Para encontrar o estimador de máxima verossimilhança, em geral, segue-se os seguintes passos:

1. Encontrar  $L(\theta; \mathbf{x})$ ,  $\mathbf{x} = (x_1, x_2, \dots, x_n)$
2. Encontrar a função log-verossimilhança:  $l(\theta; \mathbf{x}) = \log L(\theta; \mathbf{x})$
3. Derivar  $l(\theta; \mathbf{x})$  em relação a  $\theta$  e igualar a 0:  $\frac{\partial l(\theta; \mathbf{x})}{\partial \theta} = 0$
4. Derivar novamente para provar que o ponto encontrado no passo 3 é o máximo:  $\frac{\partial^2 l(\theta; \mathbf{x})}{\partial \theta^2}$

Note que, em suma, estamos **maximizando** a função de verossimilhança, de forma que seja o mais provável possível encontrar o ponto em nossa amostra.

*Propriedades dos EMV:*

- O EMV é sempre função de uma estatística suficiente para o parâmetro
- Se  $\hat{\theta}$  é um EMV, então  $g(\hat{\theta})$  é o EMV para  $g(\theta)$  [8]

- Para grandes amostras:  $\sqrt{n} (g(\hat{\theta}) - g(\theta)) \stackrel{a}{\sim} N\left(0, \frac{[g'(\theta)]^2}{I_F(\theta)}\right)$  [9]

## Método dos mínimos quadrados

Ao contrário dos estimadores de máxima verossimilhança, onde queremos maximizar uma função, nos mínimos quadrados, como o próprio nome sugere, vamos **minimizar** uma soma de quadrados, que na verdade é a soma dos quadrados dos desvios  $(X - E[X])^2$ . Veja os passos a seguir:

1. Encontre  $S(x) = \sum_{i=1}^n (X_i - E[X_i])^2$
2. Faça  $S'(x) = 0$
3. Mostre que  $S''(x) > 0$  para provar que o ponto encontrado no passo 2 é de mínimo

## Exercícios Resolvidos 3

1. Seja  $X \sim Exp(\theta)$ . Encontre o estimador pelo método dos momentos.

$$\mu = \bar{X} \quad \therefore \quad \frac{1}{\theta} = \bar{X} \quad \therefore \quad \theta_{MM} = \frac{1}{\bar{X}}$$

2. Seja  $X \sim U(0; \theta)$ . Encontre o estimador pelo método dos momentos.

$$\mu = \bar{X} \quad \therefore \quad \frac{\theta}{2} = \bar{X} \quad \therefore \quad \theta_{MM} = 2\bar{X}$$

3. Ache o estimador pelo método da máxima verossimilhança para a v.a do item 1.

$$3.1. L(\theta) = \prod_{i=1}^n f(x_i|\theta) = \prod_{i=1}^n \theta e^{-\theta x_i} = \theta^n e^{-\theta s}$$

com  $s = \sum_{i=1}^n X_i$

$$3.2. l(\theta) = \log L(\theta) = n \log \theta - \theta s$$

$$3.3. l'(\theta) = \frac{n}{\theta} - s$$

$$3.4. \frac{n}{\theta} = s \quad \therefore \quad \frac{1}{\theta} = \bar{X} \quad \therefore \quad \theta_{MV} = \frac{1}{\bar{X}}$$

$$3.5. l''(\theta) = -\frac{n}{\theta^2} < 0, \text{ portanto, ponto de máximo}$$

4. Ache o estimador de máxima verossimilhança para a seguinte v.a:

$$f(x|\theta) = \frac{x}{\theta^2} \exp\left(-\frac{x}{\theta}\right) I_A(x), A = (0, \infty), \theta > 0. \text{ Verifique se ele é eficiente.}$$

$$4.1. L(\theta) = \prod_{i=1}^n f(x_i|\theta) = \prod_{i=1}^n \frac{x_i}{\theta^2} \exp\left(-\frac{x_i}{\theta}\right) = \theta^{-2n} e^{-\frac{s}{\theta}} \prod_{i=1}^n x_i, \text{ com } s = \sum_{i=1}^n x_i$$

$$4.2. l(\theta) = -2n \log \theta - \frac{s}{\theta} + \sum_{i=1}^n \log x_i$$

$$4.3. l'(\theta) = \frac{-2n}{\theta} + \frac{s}{\theta^2}$$

$$4.4. \theta_{MV} = \frac{s}{2n} = \frac{\bar{X}}{2}$$

$$4.5. l''(\theta) = \frac{2n}{\theta^2} - \frac{2s}{\theta^3} = \frac{2n}{\theta^2} - \frac{2n\bar{X}}{\theta^3} < 0, \text{ logo, ponto de máximo.}$$

Veremos agora se ele é eficiente:

$$4.6. \log f(x|\theta) = \log X - 2 \log \theta - \frac{x}{\theta}$$

$$4.7. V = -\frac{2}{\theta} + \frac{x}{\theta^2}$$

$$4.8. Var[V] = \frac{1}{\theta^4} Var[X] = \frac{2}{\theta^2} = I_F(\theta), \text{ pois } Var[X] = 2\theta^2; X \sim Gama(\frac{1}{\theta}, 2)$$

$$4.9. LICR = \frac{1}{n \frac{2}{\theta^2}} = \frac{\theta^2}{2n}$$

$$4.9.1 e\left(\frac{\bar{X}}{2}\right) = \frac{\frac{\theta^2}{2n}}{Var\left[\frac{\bar{X}}{2}\right]} = 1. \text{ Nosso estimador é eficiente}$$

5. Ache o estimador pelo método dos mínimos quadrados para a v.a do item 1.

$$5.1. S(\theta) = \sum_{i=1}^n (X_i - E[X_i])^2 = \sum_{i=1}^n (X_i - \frac{1}{\theta})^2 = \sum_{i=1}^n X_i^2 - 2n\bar{X}\frac{1}{\theta} + \frac{n}{\theta^2}$$

$$5.2. S'(\theta) = \frac{2n\bar{X}}{\theta^2} - \frac{2n}{\theta^3}$$

$$5.3. \theta_{MM} = \frac{1}{\bar{X}}$$

$$5.4. S''(\theta) = \frac{-4n\bar{X}}{\theta^3} + \frac{6n}{\theta^4} > 0, \text{ portanto, ponto de mínimo}$$

6. Considere o modelo de regressão:  $\beta\sqrt{X_i} + u_i, i = 1, 2, n$ , com  $u_i$ 's independentes. Considere também que  $E[u_i] = 0$  e  $Var[u_i] = \sigma^2$ . Encontre o EMQ de  $\beta$ .

$$S(\beta) = \sum_{i=1}^n (Y_i - E[Y_i])^2. \text{ Vamos encontrar a esperança e variância de } Y_i \text{ primeiro:}$$

$$6.1. E[Y_i] = E[\beta\sqrt{X_i} + u_i] = E[\beta\sqrt{X_i}] + E[u_i] = \beta\sqrt{X_i}$$

$$6.2. Var[\beta\sqrt{X_i} + u_i] = Var[u_i] = \sigma^2$$

Agora, vamos prosseguir.

$$6.3. S(\beta) = \sum_{i=1}^n (Y_i^2 - 2Y_i\beta\sqrt{X_i} + \beta^2 X_i) = \sum_{i=1}^n Y_i^2 - 2\beta \sum_{i=1}^n Y_i\sqrt{X_i} + \beta^2 \sum_{i=1}^n X_i$$

$$6.4. S'(\beta) = -2 \sum_{i=1}^n Y_i\sqrt{X_i} + 2\beta \sum_{i=1}^n X_i \quad \therefore \quad \beta = \frac{\sum_{i=1}^n Y_i\sqrt{X_i}}{\sum_{i=1}^n X_i}$$

$$6.5. S''(\beta) = 2 \sum_{i=1}^n X_i > 0, \text{ logo, ponto de m\u00ednimo}$$

7. Para o item 1., encontre o EMV de  $P(X > 2) = g(\theta)$  e sua distribui\u00e7\u00e3o em grandes amostras.

$$7.1. P(X > 2) = 1 - P(X \leq 2) = 1 - [1 - e^{-2\theta}] = e^{-2\theta} = g(\theta)$$

$$7.2. \text{ Pelo princ\u00edpio da invari\u00e2ncia, } g(\hat{\theta}) = g(\theta) \quad \therefore \quad g(\hat{\theta}) = e^{-\frac{2}{\hat{x}}}$$

7.3. J\u00e1 vimos anteriormente que  $I_F(\theta) = \frac{1}{\theta^2}$ . \u00c9 f\u00e1cil ver tamb\u00e9m que  $[g'(\theta)]^2 = 4e^{-4\theta}$ . Logo, em grandes amostras:

$$\sqrt{n}(g(\hat{\theta}) - g(\theta)) \overset{a}{\sim} N(0; 4\theta^2 e^{-4\theta})$$

## Estima\u00e7\u00e3o intervalar

Estima\u00e7\u00f5es intervalares, ou seja, entre intervalos, s\u00e3o constru\u00eddas atrav\u00e9s do m\u00e9todo da **quantidade pivotal**, que \u00e9 uma vari\u00e1vel aleat\u00f3ria especial, cuja distribui\u00e7\u00e3o **n\u00e3o** depende de par\u00e2metros desconhecidos.

Tais estimativas partem da vertente frequentista da estat\u00edstica, sob a seguinte interpreta\u00e7\u00e3o: para um n\u00famero grande de vezes, e sob as mesmas circunst\u00e2ncias de realiza\u00e7\u00e3o, o par\u00e2metro a ser estimado encontra-se dentro de X% dos intervalos encontrados, onde X \u00e9 o n\u00edvel de confian\u00e7a pr\u00e9-estabelecido.

Geralmente, s\u00e3o estabelecidos n\u00edveis  $\gamma = 1 - \alpha$  de confian\u00e7a de 90%, 95% e 99%, onde  $\alpha$  \u00e9 o n\u00edvel de signific\u00e2ncia. Por\u00e9m, outros n\u00edveis de confian\u00e7a podem tamb\u00e9m ser utilizados. Entretanto, deve-se observar a influ\u00eancia do mesmo no comprimento do intervalo, como ser\u00e1 visto a seguir.

## Intervalos Bilaterais

1. Seja  $X_1, X_2, \dots, X_n$  uma A.A com distribui\u00e7\u00e3o  $N(\mu, \sigma^2)$ .

- Intervalo de confiança para  $\mu$ , com  $\sigma^2$  **conhecida** [\[10\]](#):

$$\left[ \bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}; \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

Quantidade pivotal:  $Q = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0; 1)$

- Intervalo de confiança para  $\mu$ , com  $\sigma^2$  **desconhecida**:

$$\left[ \bar{X} - t_{\alpha/2} \frac{S}{\sqrt{n}}; \bar{X} + t_{\alpha/2} \frac{S}{\sqrt{n}} \right]$$

Quantidade pivotal:  $Q = \frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}} \sim t_{(n-1)}$

- Intervalo de confiança para  $\sigma^2$ :

$$\left[ \frac{(n-1)S^2}{q_2}; \frac{(n-1)S^2}{q_1} \right]$$

Quantidade pivotal:  $Q = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{(n-1)}$

2. Seja  $X_1, X_2, \dots, X_n$  uma A.A com distribuição  $Exp(\theta)$ .

Intervalo de confiança para  $\theta$ :

$$\left[ \frac{q_1}{2S}; \frac{q_2}{2S} \right]$$

Quantidade pivotal:  $Q = 2\theta S \sim \chi_{(2n)}, S = \sum_{i=1}^n X_i \sim \text{Gama}(n; \theta)$

3. Seja  $X_1, X_2, \dots, X_n$  uma A.A com distribuição  $\text{Ber}(p)$ .

Intervalo de confiança de MV para  $p$ :

$$\left[ \hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}; \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]$$

Onde  $\hat{p}$  é o estimador de máxima verossimilhança para  $p$ .

Quantidade pivotal:  $Q = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim N(0; 1)$

É importante salientar que existem outros intervalos para a proporção populacional, como o **conservador** e o de **MV com fator de correção**. Porém, por terem notações muito extensas, não serão colocados aqui.

4. Seja  $X_1, X_2, \dots, X_n$  uma A.A de tamanho  $n$  com distribuição  $N(\mu_1, \sigma_1^2)$ . Temos que  $\bar{X}$  e  $S_1^2$  são **independentes**. Agora, seja  $Y_1, Y_2, \dots, Y_m$  uma A.A de tamanho  $m$  com distribuição  $N(\mu_2, \sigma_2^2)$ . Temos que  $\bar{Y}$  e  $S_2^2$  são **independentes**. Temos também que  $U = \frac{(n-1)S_1^2}{\sigma_1^2} \sim \chi_{(n-1)}^2$  e  $V = \frac{(m-1)S_2^2}{\sigma_2^2} \sim \chi_{(m-1)}^2$ . As variáveis  $\bar{X}, \bar{Y}, U$  e  $V$  são **independentes** entre si. [\[11\]](#)

◦ Intervalo de confiança para  $\mu_1 - \mu_2$ , com  $\sigma_1^2$  e  $\sigma_2^2$  **conhecidas**:

$$\left[ (\bar{X} - \bar{Y}) - z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}; (\bar{X} - \bar{Y}) + z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}} \right]$$

Quantidade pivotal:  $Q = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} \sim N(0, 1)$

◦ Intervalo de confiança para  $\mu_1 - \mu_2$ , com  $\sigma_1^2 = \sigma_2^2$  **desconhecidas**:

$$\left[ (\bar{X} - \bar{Y}) - t_{\alpha/2} S_p \sqrt{\frac{1}{n} + \frac{1}{m}}; (\bar{X} - \bar{Y}) + t_{\alpha/2} S_p \sqrt{\frac{1}{n} + \frac{1}{m}} \right]$$

Onde  $S_p = \sqrt{\frac{(n-1)S_1^2 + (m-1)S_2^2}{n+m-2}}$ .

Quantidade pivotal:  $Q = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{S_p \sqrt{\frac{1}{n} + \frac{1}{m}}} \sim t_{(n+m-2)}$

- Intervalo de confiança para  $\mu_1 - \mu_2$ , com  $\sigma_1^2 \neq \sigma_2^2$  **desconhecidas**:

$$\left[ (\bar{X} - \bar{Y}) - t_{\alpha/2} \sqrt{\frac{S_1^2}{n} + \frac{S_2^2}{m}}; (\bar{X} - \bar{Y}) + t_{\alpha/2} \sqrt{\frac{S_1^2}{n} + \frac{S_2^2}{m}} \right]$$

Quantidade pivotal:  $Q = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{S_1^2}{n} + \frac{S_2^2}{m}}} \sim t_{(r)}$ , onde  $r = \frac{(A+B)^2}{\frac{A^2}{n-1} + \frac{B^2}{m-1}}$ , com  $A = \frac{S_1^2}{n}$  e

$B = \frac{S_2^2}{m}$ .  $r$  é o número inteiro mais próximo.

- Intervalo de confiança para  $\frac{\sigma_1^2}{\sigma_2^2}$ :

$$\left[ f_1 \frac{S_2^2}{S_1^2}; f_2 \frac{S_2^2}{S_1^2} \right]$$

Quantidade pivotal:  $Q = \frac{S_1^2}{S_2^2} \frac{\sigma_2^2}{\sigma_1^2} \sim F(n-1; m-1)$

5. Seja  $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$  uma A.A de  $(X, Y) \sim N(\mu_1, \mu_2; \rho, \sigma_1^2, \sigma_2^2)$ .

Intervalo de confiança para  $D = X - Y$ :



$$\left[ \bar{D} - t_{\alpha/2} \frac{S_D}{\sqrt{n}}; \bar{D} + t_{\alpha/2} \frac{S_D}{\sqrt{n}} \right]$$

Quantidade pivotal:  $Q = \frac{\bar{D} - \mu_D}{S_D/\sqrt{n}} \sim t_{(n-1)}$

Quando temos amostras advindas de processos SEM REPOSIÇÃO, multiplicamos os limites pelo fator de correção  $\frac{N-n}{N-1}$ . [\[12\]](#)

Note que, nos intervalos para a média populacional, o valor de  $\bar{X}$  pode ser encontrado da seguinte forma:  $\bar{X} = \frac{li + ls}{2}$

## Intervalos Unilaterais

A definição de intervalos de confiança, sejam eles bilaterais ou unilaterais, está intrinsecamente ligada à testes de hipótese, pois é a partir de hipóteses pré formuladas que se constroem tais intervalos.

Há dois tipos de hipóteses:  $H_0$  e  $H_1$ , que correspondem respectivamente à hipótese nula (“principal”) e à hipótese alternativa (“secundária”).

As mesmas ainda podem ser classificadas em duas categorias:

- Simples: quando os valores supostos **são exatos** (ou seja, são iguais a um valor X)
- Compostas: quando os valores **não são exatos** (ou seja, são maiores, menores ou diferentes de um valor X)

O tipo de intervalo que é construído para testar as hipóteses, é baseado na direção da hipótese alternativa.

Quando  $H_1$  é da forma  $H_1 : \mu \neq X$ , construímos intervalos bilaterais, pois o valor real pode estar tanto acima quanto abaixo do valor suposto em  $H_0$ .

Já quando  $H_1$  é da forma  $H_1 : \mu > X$  ou  $H_1 : \mu < X$ , usamos intervalos unilaterais, pois o valor real só se encontra ou acima ou abaixo do valor suposto em  $H_0$ .

1. Para  $H_1 : \mu > X$ , temos um intervalo unilateral **à direita** ou **superior**.
2. Para  $H_1 : \mu < X$ , temos um intervalo unilateral **à esquerda** ou **inferior**.

Para construir esses intervalos, procedemos da mesma forma que os intervalos bilaterais já vistos, com a diferença de que, se a hipótese alternativa for da primeira forma, então temos  $IC[-\infty, ls]$ . Caso

tenhamos a segunda forma, ficamos com  $IC[li, \infty]$ .

Para proporções, a diferença é que substituímos  $-\infty \rightarrow 0$ , e  $\infty \rightarrow 1$ .

## Testes de Hipótese

Como visto anteriormente, testes de hipótese estão diretamente relacionados à construção de intervalos de confiança. Porém, para a construção dos mesmos, precisamos estabelecer previamente as hipóteses nula e alternativa, a fim de poder analisar e elucidar um resultado posteriormente.

Entretanto, ao optar por uma hipótese, nos sujeitamos a dois tipos de erro, que são eles:

- *Erro de tipo I*: rejeitar  $H_0$  sendo  $H_0$  verdade
- *Erro de tipo II*: não rejeitar  $H_0$  sendo  $H_0$  falsa

Na Inferência, o cálculo da probabilidade de ambos os erros recebem nomenclaturas especiais, sendo elas:

- $\alpha$  o **tamanho do erro de tipo I**, que é  $P(\text{Rejeitar } H_0 | H_0 \text{ verdade})$
- $\beta$  o **tamanho do erro de tipo II**, que é  $P(\text{Não rejeitar } H_0 | H_0 \text{ falsa})$

Note que  $\alpha$  também é o *nível de significância*, geralmente fixado em 5%, 2% ou 1%.

Outro fator muito relevante neste conteúdo é o cálculo do *valor-p*, sendo o mesmo a probabilidade de encontrar um valor pelo menos tão extremo quanto o observado na amostra, **respeitando a direção** de  $H_1$ .

Assim, o *valor-p* é, na verdade, o menor nível de significância encontrado, ou seja, pode ser comparado ao  $\alpha$  estabelecido para saber se deve-se rejeitar ou não  $H_0$ .

Outra medida importante no estudo dos testes de hipótese é a **função poder**, possuindo a forma  $\pi(\theta) = P(\text{Rejeitar } H_0 | \theta)$ , sendo  $\theta$  um valor qualquer para o parâmetro estimado, digamos,  $\theta$ . Assim:

- $\pi(\theta_0) = \alpha$
- $\pi(\theta_1) = 1 - \beta \Rightarrow P(\text{Rejeitar } H_0 | \theta_1) = 1 - P(\text{Não Rejeitar } H_0 | \theta_1) = 1 - \beta$

Assim, a função poder e a construção de gráficos de poder são basedas no complementar do tamanho do erro de tipo II.

## Métodos

A fim de resumir os procedimentos possíveis para se analisar hipóteses, listo a seguir as formas vistas na disciplina.

1. *Intervalos de Confiança*: o valor de  $H_0$  encontra-se dentro ou fora do intervalo encontrado?
2. *Região Crítica (R.C) e Região de Aceitação (R.A)*: a estatística encontra-se na R.C ou na R.A?
3. *Valor-p*:  $\alpha > \hat{\alpha}$ ? Ou  $\alpha < \hat{\alpha}$ ?
4. *Estatística de teste*:  $z_{calc} > z_{tab}$ ? Ou  $z_{calc} < z_{tab}$ ?<sup>[13]</sup>

## Procedimentos em uma amostra

1.  $H_0 : \mu = \mu_0, \sigma^2$  conhecida

Estatística de teste:  $z_0 = \frac{\bar{x} - \mu_0}{\sigma / \sqrt{n}}$

$H_1$	Rejeita $H_0$ se
$\mu \neq \mu_0$	$ z_0  > z_{\alpha/2}$
$\mu > \mu_0$	$z_0 > z_{\alpha}$
$\mu < \mu_0$	$z_0 < -z_{\alpha}$

2.  $H_0 : \mu = \mu_0, \sigma^2$  desconhecida

Estatística de teste:  $t_0 = \frac{\bar{x} - \mu_0}{S / \sqrt{n}}$

$H_1$	Rejeita $H_0$ se
$\mu \neq \mu_0$	$ t_0  > t_{\alpha/2, (n-1)}$
$\mu > \mu_0$	$t_0 > t_{\alpha, (n-1)}$
$\mu < \mu_0$	$t_0 < -t_{\alpha, (n-1)}$

3.  $H_0 : \sigma^2 = \sigma_0^2$

Estatística de teste:  $\chi_0^2 = \frac{(n-1)S^2}{\sigma_0^2}$

$H_1$	Rejeita $H_0$ se
$\sigma^2 \neq \sigma_0^2$	$\chi_0^2 > \chi_{\alpha/2}^2, (n-1)$ ou $\chi_0^2 < \chi_{1-\alpha/2}^2, (n-1)$
$\sigma^2 > \sigma_0^2$	$\chi_0^2 > \chi_{\alpha}^2, (n-1)$
$\sigma^2 < \sigma_0^2$	$\chi_0^2 < \chi_{1-\alpha}^2, (n-1)$

4.  $H_0 : p = p_0$

Estatística de teste:  $z_0 = \frac{x - np_0}{\sqrt{np_0q_0}}$ , onde  $x$  é o número de sucessos na amostra

$H_1$	Rejeita $H_0$ se
$p \neq p_0$	$ z_0  > z_{\alpha/2}$
$p > p_0$	$z_0 > z_{\alpha}$
$p < p_0$	$z_0 < -z_{\alpha}$

## Procedimentos em duas amostras

1.  $H_0 : \mu_1 - \mu_2 = \Delta_0$ ,  $\sigma_1^2$  e  $\sigma_2^2$  conhecidas

Estatística de teste:  $z_0 = \frac{\bar{x}_1 - \bar{x}_2 - \Delta_0}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}}$

$H_1$	Rejeita $H_0$ se
$\mu_1 - \mu_2 \neq \Delta_0$	$ z_0  > z_{\alpha/2}$
$\mu_1 - \mu_2 > \Delta_0$	$z_0 > z_{\alpha}$
$\mu_1 - \mu_2 < \Delta_0$	$z_0 < -z_{\alpha}$

2.  $H_0 : \mu_1 - \mu_2 = \Delta_0$ ,  $\sigma_1^2 = \sigma_2^2$  desconhecidas

Estatística de teste:  $t_0 = \frac{\bar{x}_1 - \bar{x}_2 - \Delta_0}{S_p \sqrt{\frac{1}{n} + \frac{1}{m}}}$

$H_1$	Rejeita $H_0$ se
$\mu_1 - \mu_2 \neq \Delta_0$	$ t_0  > t_{\alpha/2}, (n + m - 2)$
$\mu_1 - \mu_2 > \Delta_0$	$t_0 > t_{\alpha}, (n + m - 2)$
$\mu_1 - \mu_2 < \Delta_0$	$t_0 < -t_{\alpha}, (n + m - 2)$

3.  $H_0 : \mu_1 - \mu_2 = \Delta_0, \sigma_1^2 \neq \sigma_2^2$  desconhecidas

Estatística de teste:  $t_0 = \frac{\bar{x}_1 - \bar{x}_2 - \Delta_0}{\sqrt{\frac{S_1^2}{n} + \frac{S_2^2}{m}}}$

$H_1$	Rejeita $H_0$ se
$\mu_1 - \mu_2 \neq \Delta_0$	$ t_0  > t_{\alpha/2}, (v)$
$\mu_1 - \mu_2 > \Delta_0$	$t_0 > t_{\alpha}, (v)$
$\mu_1 - \mu_2 < \Delta_0$	$t_0 < -t_{\alpha}, (v)$

Sendo  $v = \frac{\left(\frac{S_1^2}{n} + \frac{S_2^2}{m}\right)^2}{\frac{(S_1^2/n)^2}{n-1} + \frac{(S_2^2/m)^2}{m-1}}$

4.  $H_0 : \mu_D = 0$  (populações dependentes)

Estatística de teste:  $t_0 = \frac{\bar{d}}{s_D / \sqrt{n}}$

$H_1$	Rejeita $H_0$ se
$\mu_D \neq 0$	$ t_0  > t_{\alpha/2}, (n - 1)$
$\mu_D > 0$	$t_0 > t_{\alpha}, (n - 1)$

$H_1$	Rejeita $H_0$ se
$\mu_D < 0$	$t_0 < -t_\alpha, (n - 1)$

5.  $H_0 : \sigma_1^2 = \sigma_2^2$

Estatística de teste:  $f_0 = S_1^2/S_2^2$

$H_1$	Rejeita $H_0$ se
$\sigma_1^2 \neq \sigma_2^2$	$f_0 > f_{\alpha/2}, (n - 1, m - 1)$ ou $f_0 < f_{1-\alpha/2}, (n - 1, m - 1)$
$\sigma_1^2 > \sigma_2^2$	$f_0 > f_\alpha, (n - 1, m - 1)$

6.  $H_0 : p_1 = p_2$

Estatística de teste:  $z_0 = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}\hat{q}\left[\frac{1}{n} + \frac{1}{m}\right]}}$

$H_1$	Rejeita $H_0$ se
$p_1 \neq p_2$	$ z_0  > z_{\alpha/2}$
$p_1 > p_2$	$z_0 > z_\alpha$
$p_1 < p_2$	$z_0 < -z_\alpha$

## Teste mais poderoso

O lema de Neyman-Pearson nos diz que o teste mais poderoso será aquele de região crítica dada por

$$A^* = \left\{ \mathbf{x}; \frac{L_1(\mathbf{x})}{L_0(\mathbf{x})} \geq c \right\}$$

Caso  $A^*$  **não** dependa do parâmetro a ser testado, então dizemos que o teste realizado é, na verdade, o teste uniformemente mais poderoso (**UMP**).

---

1. logo, **todo estimador é uma estatística**, mas nem toda estatística é um estimador. ↵
2. um estimador pode subestimar ou superestimar um parâmetro. ↵
3. se o estimador for **não viesado**, então o EQM será a variância do estimador. ↵
4. é a distribuição conjunta da amostra analisada como função de  $\theta$  ↵
5. em algumas situações, é mais fácil usar a última forma, pois a variância torna-se mais difícil de encontrar! ↵
6. esse resultado é conhecido como **critério da fatoração de Neyman**, e é mais utilizado quando o suporte da distribuição depender do parâmetro; do contrário, encontra-se a estatística suficiente através da família exponencial ↵
7. A ideia é que dado um estimador não-viesado e que seja função de uma estatística suficiente, então, tal estimador é o UMVUE ↵
8. este é o princípio da **invariância** ↵
9. distribuição assintótica dos EMV ↵
10.  $e = z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$  é o erro amostral. Quando o mesmo é especificado e queremos achar o tamanho da amostra, temos o seguinte:  $n = \left\lceil \left( \frac{z_{\alpha/2} \sigma}{e} \right)^2 \right\rceil$ . A situação é similar quando a variância é desconhecida, ou para quando temos duas populações ↵
11. há uma regra prática para decidir se as variâncias são iguais ou distintas: se  $\frac{\max(S_1^2, S_2^2)}{\min(S_1^2, S_2^2)} < 4$ , então, considerar **variâncias iguais** ↵
12. nesses casos, para encontrar o tamanho amostral, usamos agora  $n = \frac{z_{\alpha/2}^2 \sigma^2 N}{(N-1)e^2 + z_{\alpha/2}^2 \sigma^2}$  para estimar a média, e  $n = \frac{z_{\alpha/2}^2 \bar{p} \bar{q} N}{(N-1)e^2 + z_{\alpha/2}^2 \bar{p} \bar{q}}$  para estimar a proporção ↵
13. este é um tipo de região crítica, utilizando a estatística de teste ao invés da estatística observada ↵